CHURN PROJECT - MAL - ENSIIE

Halimata Ndiaye

December 2025

Contents

1 Introduction **3**

2 Analyse exploratoire et prétraitement **3**
2.1 Présentation du jeu de données . . . 3
2.2 Visualisation des variables continues . . . 3
2.3 Visualisation des variables catégorielles . . . 4
2.4 Prétraitement des données . . . 4

3 Méthodologie **4**
3.1 Modèles . . . 4
3.2 Détection d'anomalies . . . 5

4 Résultats **5**
4.1 Comparaison initiales des modèles . . . 5
4.2 Turning des hyperparamètres . . . 5
4.3 Performance des modèles optimisés . . . 5
4.4 Importance des variables . . . 6
4.5 Analyse de fairness vis-à-vis de `Gender` . . . 6
4.5.1 Independence . . . 6
4.6 Separation (TPR et FPR par genre) . . . 6
4.6.1 Sufficiency (calibration conditionnelle) . . . 7

5 Conclusion **7**

1 Introduction

La fidélisation de la clientèle représente un enjeu majeur pour les opérateurs de télécommunications, dans un marché fortement concurrentiel où les clients peuvent changer d'offre ou d'opérateur très facilement. Le départ d'un client vers un concurrent, appelé *churn*, entraîne non seulement une perte de revenus, mais aussi des coûts supplémentaires liés à l'acquisition de nouveaux abonnés. Or, dans tout le secteur de service, dû au coût du marketing il est généralement admis qu'il est moins couteux de retenir un client existant que d'en attirer un nouveau. Il est donc important pour un opérateur mobile de disposer d'outils fiables pour anticiper le churn et connaître les *features* (caractéristiques des clients et de leur usage du service) qui l'entrainent afin d'agir pour retenir les clients.

Dans cette optique, ce rapport porte sur l'étude d'un jeu de données de clients d'un opérateur téléphonique dabs le but de modéliser et de prédire la probabilité de churn à l'aide de méthodes d'apprentissage automatique supervisé. Les *features* permettant de comprendre quels facteurs sont le plus fortement associés au churn et d'orienter les décisions marketing, une attention particulière leur sera donc portée au long de l'étude. Nous analyserons ensuite l'équité de ces modèles vis-à-vis de la variable sensible Gender selon les critères d'Independence, Separation et Sufficiency.

2 Analyse exploratoire et prétraitement

2.1 Présentation du jeu de données

Le jeu de données étudié est constitué de 8 000 observations, chacune correspondant à un client de l'opérateur téléphonique, et de 11 variables. Toutes les observations sont complètes, c'est-à-dire qu'aucune valeur manquante n'est présente dans le DataFrame. Les variables comprennent 8 colonnes numériques entières, 1 colonne numérique continue et 2 colonnes catégorielles.

Ces variables couvrent des dimensions démographiques (âge, genre, localisation), financières (score de crédit, solde, revenu), ainsi que des informations d'engagement vis-à-vis de l'opérateur (ancienneté, nombre de produits, activité, carte de crédit). Elles constituent les *features* sur lesquelles s'appuie l'analyse exploratoire puis la modélisation pour expliquer et prédire le churn.

2.2 Visualisation des variables continues

Pour analyser la relation entre les variables continues et le churn, nous avons tracé, pour chaque feature numérique (`CreditScore`, `Age`, `Balance`, `Salary`, `Tenure`,), la distribution conditionnelle au statut de churn. Ces visualisations permettent de comparer visuellement les profils des deux groupes.

De manière générale, les distributions des variables continues se chevauchent fortement entre churners et non-churners, ce qui suggère qu'aucune de ces variables, prise isolément, ne sépare nettement les deux populations. La différence la plus marquée est observée pour l'âge : les clients churners apparaissent en moyenne légèrement plus âgés que les non-churners, ce qui rejoint les premiers résultats de la matrice de corrélation.

Nous avons ensuite calculé la matrice de corrélation visualisée sous forme de heatmap afin de mettre en évidence les relations linéaires entre ces variables continues et la variable cible. Cette matrice met en évidence une corrélation positive modérée entre l'âge et le churn, tandis que les autres variables (score de crédit, solde, etc.) présentent des corrélations plus faibles en valeur absolue. Ces résultats indiquent que, pour prédire le churn, il sera nécessaire de s'appuyer sur une combinaison de plusieurs features plutôt que sur une seule variable explicative.

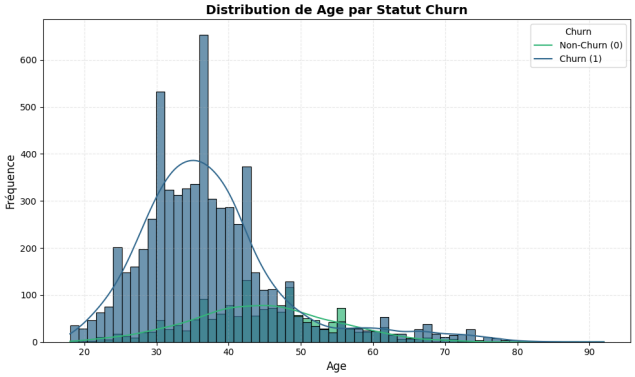

Figure 1: Distribution de l'age par statut churn

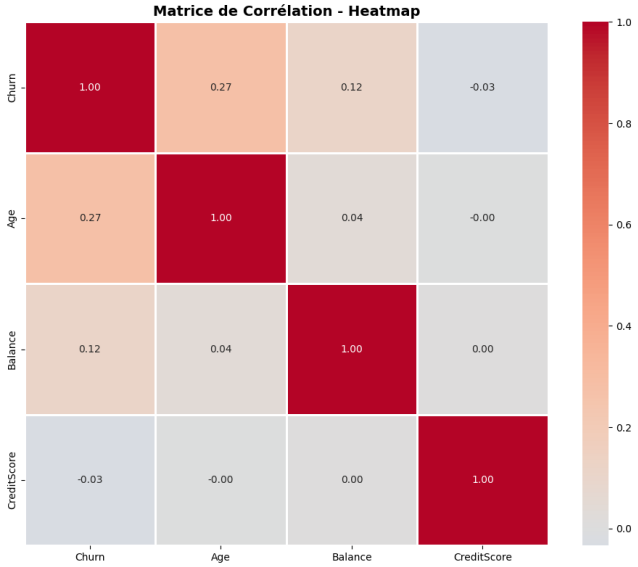

Figure 2: Heatmap - Matrice de corrélation

2.3 Visualisation des variables catégorielles

Pour chaque variable catégorielle (`Geography`, `Gender`, `NumOfProducts`, `HasCrCard`, `IsActiveMember`), nous avons tracé des histogrammes séparant les clients churners et non-churners. Ces graphiques permettent de comparer visuellement, au sein de chaque catégorie, la proportion de clients ayant résilié leur contrat.

Plusieurs tendances fortes se dégagent. Le taux de churn atteint environ 31 % en Allemagne, contre 16,5 % en France et en Espagne. Les femmes présentent environ 12 % de churn en plus que les hommes. Le nombre de produits est également très discriminant : le churn est d'environ 7,4 % pour deux produits, 27,2 % pour un produit et atteint près de 83 % pour trois produits. Enfin, les clients actifs (`IsActiveMember = 1`) churnent nettement moins que les clients inactifs, tandis que `HasCrCard` montre des différences beaucoup plus faibles entre ses modalités.

2.4 Prétraitement des données

Avant l'entraînement des modèles, les données ont été préparées afin d'être directement exploitables par les algorithmes de classification. Les variables catégorielles `Geography` et `Gender` ont été transformées en variables indicatrices (one-hot encoding). Les variables numériques continues (`CreditScore`, `Age`, `Balance`, `Salary`) ont été mises sur une échelle comparable pour les modèles sensibles à la norme des features. Enfin, le jeu de données a été divisé en ensembles d'apprentissage et de test en vue de l'évaluation des performances des modèles.

3 Méthodologie

3.1 Modèles

Le problème étudié étant une classification binaire de churn, nous avons retenu un ensemble restreint de modèles largement utilisés et reconnus pour leurs bonnes performances dans ce type de contexte. Cinq modèles sont ainsi considérés : la régression logistique (`LogReg`), le k plus proches voisins (`KNN`), l'arbre de décision (`Tree`), la forêt aléatoire (`RF`) et le gradient boosting (`GB`).

La régression logistique est choisie comme modèle de référence pour son caractère simple et très interprétable. Les modèles à base d'arbres (`Tree`, `RF`, `GB`) sont inclus car ils font partie des approches les plus performantes en pratique sur les problèmes de churn et gèrent bien les interactions entre variables. Enfin, le `KNN` une méthode non paramétrique, permettant de comparer un comportement basé sur la similarité locale des clients à celui des modèles plus complexes. Cette sélection offre ainsi un compromis entre interprétabilité et performance prédictive. Les données étant déséquilibré le meilleur modèle sera ensuite choisit ayant le meilleur F1-score sur la classe churn. Une fonction `eval_model` est définie pour entraîner chaque modèle sur l'échantillon d'apprentissage et calculer les métriques suivantes : accuracy et F1 sur le train, puis accuracy, précision, rappel, F1 et AUC ROC sur le test.

3.2 Détection d'anomalies

Avant d'entraîner les modèles de classification, nous avons testé l'effet d'un nettoyage des données par détection d'anomalies. Un modèle `IsolationForest` est calibré sur l'échantillon d'apprentissage pour repérer les observations atypiques. La prédiction `iso.predict(X_train)` renvoie `1639` pour les points considérés comme normaux (inliers) et `3961` pour les outliers, ce qui permet de définir un sous-ensemble d'apprentissage nettoyé `(X_train_if, y_train_if)`. Les modèles sont ensuite évalués dans deux scénarios : sans filtrage (`without_if`) et avec filtrage (`with_if`).

4 Résultats

4.1 Comparaison initiales des modèles

Pour chaque modèle et pour chacun des scénarios (avec ou sans filtrage d'anomalies), la fonction `eval_model` est appelée et les résultats sont regroupés dans deux DataFrames `df_res_no_if` et `df_res_if`, puis fusionnés dans `df_results`. Le tableau est ensuite trié selon les métriques `f1_test` et `auc_test` afin d'identifier les modèles les plus performants.

Les meilleurs scores de F1 sont obtenus dans le scénario sans filtrage par `IsolationForest`,ce prétraitement n'apporte donc pas d'amélioration notable sur ce jeu de données. Parmi ces résultats, le Gradient Boosting ressort comme l'un des modèles les plus performants, on retient en plus l'arbre de décision est retenu pour une analyse plus détaillée en raison de sa forte interprétabilité : il permet de visualiser directement les règles de décision et de mettre en évidence les features les plus importantes pour expliquer le churn, ce qui est particulièrement pertinent dans un contexte métier où la compréhension des facteurs de risque est aussi importante que la performance prédictive.

4.2 Turning des hyperparamètres

Pour affiner les deux modèles retenus, les principaux hyperparamètres sont ajustés par une recherche en grille avec validation croisée (GridSearchCV). Une grille de valeurs plausibles est définie pour chaque modèle. Pour chaque combinaison de la grille, le modèle est entraîné et évalué par validation croisée sur le train, en utilisant le F1-score comme critère. La combinaison donnant le meilleur F1 moyen est sélectionnée, et le modèle final est ensuite ré-entraîné sur l'ensemble du train avec ces hyperparamètres.

Pour l'arbre de décision, nous faisons varier par exemple `max_depth` dans l'ensemble $\{3, 5, 7, 9, None\}$. La recherche par validation croisée (`GridSearchCV`) indique que la meilleure configuration correspond à `max_depth = 9`, avec un F1 moyen en validation croisée de 0.57.

Pour le Gradient Boosting, nous considérons le nombre d'arbres et le taux d'apprentissage. GridSearchCV sélectionne la combinaison 200 et 0.05 avec un F1 moyen de 0.58. Le learning_rate contrôle ici la contribution de chaque nouvel arbre : une valeur plus faible associée à davantage d'arbres permet souvent une meilleure généralisation.

4.3 Performance des modèles optimisés

Les versions optimisées de l'arbre de décision et du Gradient Boosting sont ensuite évaluées sur l'échantillon de test. Les matrices de confusion, les rapports de classification et les AUC montrent que l'arbre de décision atteint une F1 et une AUC légèrement inférieures à celles du Gradient Boosting, mais reste intéressant grâce à sa forte interprétabilité et à la clarté de ses règles de décision. Le Gradient Boosting obtient la meilleure combinaison F1/AUC sur le test, ce qui en fait le modèle prédictif le plus performant pour le churn dans notre étude.

Les courbes ROC confirment cette hiérarchie : la courbe du Gradient Boosting se situe globalement au-dessus de celle de l'arbre, traduisant une meilleure capacité de discrimination entre churners et non-churners pour l'ensemble des seuils de décision.

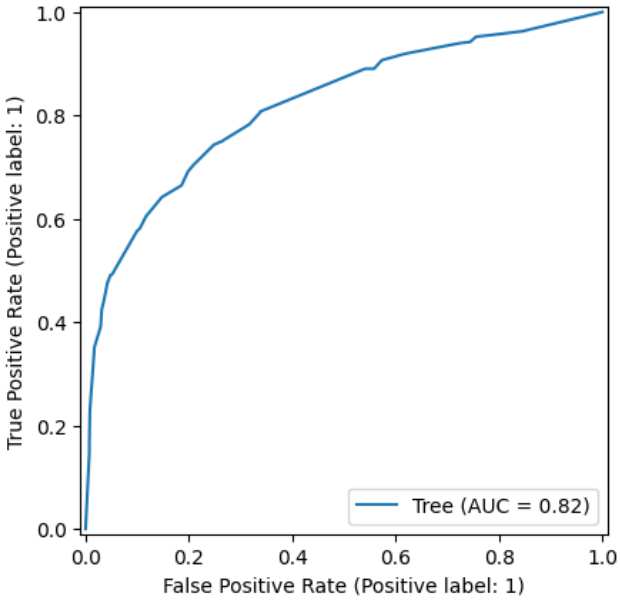

Figure 3: Courbe ROC pour Tree

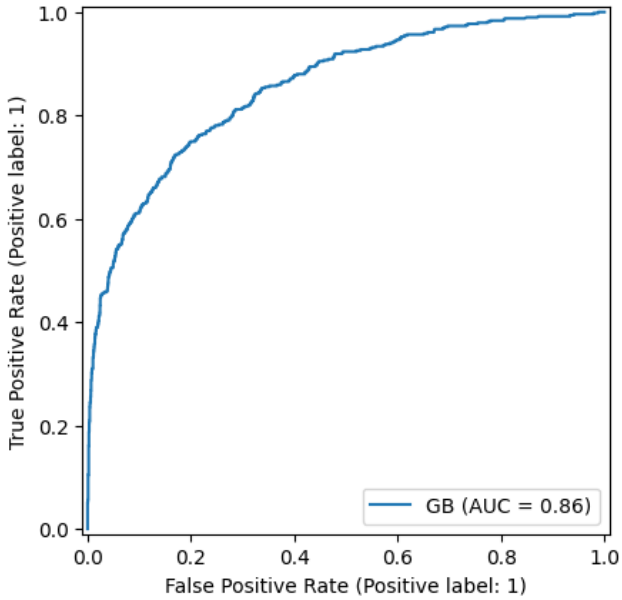

Figure 4: Courbe ROC pour le GB

4.4 Importance des variables

L'importance des variables a été étudiée à partir de l'attribut `feature_importances_` de l'arbre de décision et du Gradient Boosting. Dans les deux cas, `Age` ressort comme la variable la plus influente, suivie de `NumOfProducts`. Pour l'arbre de décision, ces deux features concentrent l'essentiel de l'importance, devant `IsActiveMember`, `Geography_Germany` et `CreditScore`, tandis que les autres variables (`Balance`, `Tenure`, `Salary`, `Gender`, `HasCrCard`, `Geography_Spain`) ont un poids très faible.

Le Gradient Boosting confirme ce diagnostic tout en répartissant davantage l'importance entre plusieurs variables : `Age` et `NumOfProducts` restent dominantes, mais `Balance`, `IsActiveMember`, `Salary`, `CreditScore` et `Geography_Germany` contribuent aussi de manière non négligeable. Ces résultats sont cohérents avec l'analyse exploratoire : le risque de churn est particulièrement lié au profil d'âge, au nombre de produits souscrits, au comportement d'activité et à la situation géographique des clients.

4.5 Analyse de fairness vis-à-vis de `Gender`

La variable `Gender` est utilisée pour étudier l'équité des modèles recommandés. Nous évaluons trois familles de critères classiques : *Independence*, *Separation* et *Sufficiency*, en comparant le comportement des modèles pour les hommes et pour les femmes.

4.5.1 Independence

La parité démographique est approchée en compare la proportion de prédictions positives par genre, c'est-à-dire $P(\hat{Y} = 1 \mid Gender)$. Pour l'arbre de décision, la proportion de clients prédits comme churners est d'environ 10,3 % chez les femmes contre 7,2 % chez les hommes. Pour le Gradient Boosting, ces proportions montent à environ 18,5 % pour les femmes et 9,8 % pour les hommes. Les deux modèles émettent donc davantage d'alertes de churn pour les femmes que pour les hommes, l'écart étant plus marqué pour le Gradient Boosting.

4.6 Separation (TPR et FPR par genre)

La séparation est évaluée en comparant, pour chaque genre, le taux de vrais positifs

$$TPR = P(\hat{Y} = 1 \mid Y = 1, Gender)$$

et le taux de faux positifs

$$FPR = P(\hat{Y} = 1 \mid Y = 0, Gender).$$

Les TPR et FPR sont calculés séparément pour l'arbre de décision et pour le Gradient Boosting à partir des matrices de confusion restreintes à chaque genre. Les résultats montrent des TPR et FPR de même ordre de grandeur pour les hommes et pour les femmes pour decision tree, avec toutefois des différences plus importante pour GB.

4.6.1 Sufficiency (calibration conditionnelle)

Pour chaque modèle, les scores de probabilité de churn sont découpés en n intervalles (quantiles), puis, pour chaque bin et chaque genre, nous comparons la fréquence réelle de churn $P(Y = 1 \mid score \in bin, Gender)$. Les tableaux de calibration par genre montrent que, pour un même niveau de score, les taux réels de churn restent globalement proches entre hommes et femmes, même si quelques écarts apparaissent dans certains intervalles de score. Globalement, le Gradient Boosting présente une calibration légèrement meilleure que l'arbre de décision, mais aucun des deux modèles n'est parfaitement suffisant au sens strict.

En résumé, les modèles présentent des différences modérées de comportement entre hommes et femmes (plus d'alertes et un peu plus de variance sur les erreurs côté femmes, surtout pour le Gradient Boosting), sans toutefois mettre en évidence un biais massif.

5 Conclusion

Au vu des résultats, le Gradient Boosting apparaît comme le modèle le plus performant pour la prédiction du churn, avec les meilleurs F1-score et AUC sur l'échantillon de test. Il permet de détecter un plus grand nombre de churners pour un niveau de faux positifs comparable et offre une bonne robustesse après réglage des hyperparamètres.

L'arbre de décision constitue une alternative intéressante du fait de sa grande interprétabilité : il permet de visualiser des règles explicites et de communiquer facilement les principaux facteurs de churn afin de mettre en place des actions pour prévenir le churn, même si ses performances restent légèrement inférieures à celles du Gradient Boosting. L'analyse de fairness ne met pas en évidence de déséquilibres extrêmes entre hommes et femmes, mais révèle quelques écarts sur les taux d'erreurs ou la calibration.

Les résultats de noptre études suggèrent par exemple de proposer des offres personnalisées selon le nombre de produits et l'usage et prioriser les clients en Allemagne et plus âgés avec par exemple des offres spécifiques de fidélisation, remises temporaires ou révision de contrat